

PROJETO INTEGRADOR

Pipeline de Inteligência em Gastos Públicos

Relatório Final — Entrega 2

Análise, visualização, Machine Learning e defesa

Aluno	Carlos Ranyere da Natividade Pereira
Curso	Tecnólogo em Big Data e Inteligência Analítica
Disciplina	Projeto Integrador
Fonte de dados	API de Dados Abertos da Câmara dos Deputados
Ano-base	2024

1. Introdução

Este relatório final consolida as duas entregas do Projeto Integrador. Na primeira fase, construí um pipeline que coleta de forma automatizada as despesas da Cota para o Exercício da Atividade Parlamentar (CEAP) da Câmara dos Deputados, trata os dados e os armazena em um banco relacional. Nesta segunda fase, transformo essa base em informação: faço a análise exploratória, construo um dashboard interativo e aplico técnicas de Machine Learning para encontrar padrões e identificar despesas atípicas.

2. Objetivos

Coletar, armazenar, tratar, analisar e interpretar dados públicos de gastos parlamentares, respondendo a perguntas concretas sobre a distribuição dos recursos e sobre comportamentos que fogem do padrão.

3. API escolhida

API de Dados Abertos da Câmara dos Deputados (v2), endpoints `/deputados` e `/deputados/{id}/despesas`. A escolha está justificada no relatório parcial: fonte oficial, gratuita, documentada e com paginação adequada ao exercício de coleta automatizada.

4. Metodologia

Segui um pipeline em cinco passos, cada um isolado em um módulo Python: (1) coleta via API com paginação e retentativa; (2) tratamento e limpeza; (3) modelagem e carga em SQLite; (4) análise exploratória com geração de gráficos; (5) Machine Learning. As bibliotecas utilizadas foram `requests` (coleta), `pandas/numpy` (tratamento e análise), `matplotlib/plotly` (gráficos), `scikit-learn` (Machine Learning) e `streamlit` (dashboard).

5. Coleta, modelagem e dicionário de dados

A coleta, a modelagem (três tabelas: `deputados`, `despesas` e `fornecedores`, com chaves primárias e estrangeiras) e o dicionário de dados foram detalhados na Entrega 1. O Diagrama Entidade-Relacionamento é reproduzido abaixo para contextualizar a análise.

Diagrama Entidade-Relacionamento — Pipeline de Gastos Públicos



PK = chave primária · FK = chave estrangeira · deputados (1) —< despesas >— (1) fornecedores

Figura 1 — Modelo de dados (DER).

6. Tratamento e preparação dos dados

Datas padronizadas em ISO, valores convertidos para numérico, identificadores mantidos como texto, remoção de duplicatas e de registros sem valor líquido. Para o Machine Learning, ainda padronizei as variáveis (StandardScaler) e calculei o desvio de cada despesa em relação à média da sua própria categoria (z-score por categoria).

7. Análise exploratória dos dados

A base analisada reúne **181.714** despesas de **477** deputados, no período de 2023-11-09 a 2025-03-27, somando **R\$ 207.543.146,12**. O valor médio por despesa é de R\$ 1.142,14 e a mediana, R\$ 248,00 — a diferença entre média e mediana já antecipa uma distribuição assimétrica, com poucas despesas de valor muito alto puxando a média para cima.

Estatística	Valor
Registros	181.714
Valor total	R\$ 207.543.146,12
Valor mínimo	R\$ -4.193,99
Valor máximo	R\$ 184.428,00
Valor médio	R\$ 1.142,14
Valor mediano	R\$ 248,00



Figura 2 — Categorias que mais concentram recursos.

As categorias de maior peso costumam ser divulgação da atividade parlamentar, passagens aéreas, combustíveis e manutenção de escritórios. Isso mostra que a CEAP se concentra em poucos tipos de gasto — informação útil para priorizar a fiscalização.




Figura 3 — Evolução mensal dos gastos.

A série mensal evidencia a sazonalidade: há meses de pico e quedas associadas a recessos parlamentares, o que ajuda a contextualizar qualquer variação brusca.




Figura 4 — Deputados com maior gasto total.




Figura 5 — Fornecedores com maior concentração de valores.

O ranking de fornecedores é especialmente relevante: quando poucos fornecedores concentram muitos recursos, vale investigar se há dependência ou padrões que mereçam atenção.




Figura 6 — Gasto total por estado.




Figura 7 — Distribuição dos valores (escala log).

8. Dashboard

Construí um dashboard interativo em Streamlit (`src/dashboard.py`), executável com `streamlit run dashboard.py`. Ele lê diretamente do banco e oferece filtros por estado, partido e categoria. Cada visualização responde a uma pergunta: visão geral (quanto e quantos), evolução temporal (quando), ranking de deputados (quem gasta mais), gasto por categoria e por estado (no que e onde) e concentração de fornecedores (para quem). Os indicadores no topo (total gasto, nº de despesas, nº de deputados e ticket médio) reagem aos filtros aplicados.

9. Técnica de Machine Learning utilizada

Apliquei duas técnicas complementares, ambas não supervisionadas, porque a base não tem um rótulo a prever — o objetivo é descobrir estrutura e desvios.

9.1 Clusterização (K-Means)

Para cada deputado, montei um vetor com a proporção do gasto em cada categoria, mais o gasto total, o número de despesas e o ticket médio. Padronizei as variáveis e apliquei o K-Means. O número de grupos foi escolhido pelo coeficiente de silhueta, que indicou $k = 6$ (silhueta = 0.15). A pergunta respondida é: *existem grupos de parlamentares com perfis de despesa parecidos?*




Figura 8 — Escolha de k (cotovelo e silhueta).

9.2 Detecção de anomalias (Isolation Forest)

Para encontrar despesas atípicas, usei o Isolation Forest sobre o valor de cada despesa (em log) combinado ao seu z-score dentro da própria categoria. A contaminação foi fixada em 1%. De **173.947** despesas, **1.730** foram sinalizadas como atípicas (0.99%). A pergunta respondida é: *quais lançamentos fogem do padrão da sua categoria?*




Figura 10 — Despesas atípicas destacadas.

Deputado	UF	Categoria	Valor
Guilherme Uchoa	PE	DIVULGAÇÃO DA ATIVIDADE PA	R\$ 148.500,00
Duda Ramos	RR	DIVULGAÇÃO DA ATIVIDADE PA	R\$ 184.428,00
Professor Alcides	GO	DIVULGAÇÃO DA ATIVIDADE PA	R\$ 150.960,00
Sargento Gonçalves	RN	DIVULGAÇÃO DA ATIVIDADE PA	R\$ 149.000,00
Gustinho Ribeiro	SE	DIVULGAÇÃO DA ATIVIDADE PA	R\$ 118.350,00
Luiz Carlos Busato	RS	DIVULGAÇÃO DA ATIVIDADE PA	R\$ 125.212,00
José Rocha	BA	DIVULGAÇÃO DA ATIVIDADE PA	R\$ 129.876,00
Arlindo Chinaglia	SP	DIVULGAÇÃO DA ATIVIDADE PA	R\$ 127.500,00

10. Interpretação dos resultados

A clusterização mostrou que os deputados não gastam de forma homogênea: há grupos com perfis claramente diferentes, o que é coerente com a realidade (um deputado de estado distante tende a gastar mais com passagens, por exemplo). A silhueta moderada é esperada em dados reais e sociais, em que as fronteiras entre grupos são suaves. Já a detecção de anomalias funcionou como um filtro de priorização: ela não afirma que uma despesa é irregular, mas aponta os lançamentos que mais destoam da própria categoria — exatamente os que um auditor olharia primeiro. A maior limitação é que ambas as técnicas dependem da qualidade e da completude dos dados da API, e que a interpretação final exige conhecimento de contexto, não apenas o resultado do algoritmo.

11. Resultados obtidos

Pipeline completo e funcional, da coleta à interpretação, sobre 181.714 despesas reais; banco relacional estruturado; dashboard interativo; e dois modelos de ML com resultados interpretados.

12. Limitações

A CEAP cobre apenas a cota parlamentar, não todo o gasto público; a API apresenta instabilidade pontual (HTTP 504); e os modelos não supervisionados exigem interpretação humana — sinalizar uma anomalia não é o mesmo que comprovar irregularidade.

13. Considerações finais

O projeto mostrou, na prática, o caminho completo de um analista de dados: entender a origem do dado, coletá-lo de forma automatizada, tratá-lo, modelá-lo, analisá-lo e, por fim, extrair conhecimento com Machine Learning. Mais do que executar algoritmos, o exercício reforçou que o valor está na interpretação e na capacidade de transformar dados públicos em informação útil para a sociedade.

14. Referências

- BRASIL. Câmara dos Deputados. **Dados Abertos — API v2**. Disponível em: <https://dadosabertos.camara.leg.br>. Acesso em 2026.
- PEDREGOSA, F. et al. **Scikit-learn: Machine Learning in Python**. Journal of Machine Learning Research, 2011.
- MCKINNEY, W. **Python for Data Analysis**. O'Reilly, 2022.
- LISKOV, B.; GUTTAG, J. Documentação oficial das bibliotecas pandas, matplotlib, plotly e streamlit. Acesso em 2026.