

PROJETO INTEGRADOR

Pipeline de Inteligência em Gastos Públicos

Relatório Parcial — Entrega 1

Coleta, modelagem e armazenamento dos dados

Aluno	Carlos Ranyere da Natividade Pereira
Curso	Tecnólogo em Big Data e Inteligência Analítica
Disciplina	Projeto Integrador
Fonte de dados	API de Dados Abertos da Câmara dos Deputados
Ano-base	2024

1. Introdução

Este relatório parcial documenta a primeira etapa do Projeto Integrador, cujo objetivo é construir um pipeline de dados sobre gastos públicos. Optei por trabalhar com as despesas da Cota para o Exercício da Atividade Parlamentar (CEAP) dos deputados federais, obtidas diretamente da API de Dados Abertos da Câmara dos Deputados. Nesta fase, o foco não está em gerar gráficos, e sim em garantir uma base confiável: coletar os dados de forma automatizada, compreendê-los, tratá-los e armazená-los de maneira estruturada para as análises da Entrega 2.

2. Objetivo da coleta

Reunir, de forma reproduzível, o conjunto de despesas dos deputados em exercício referentes ao ano de 2024, de modo a permitir responder perguntas como: quais categorias concentram mais recursos? Como os gastos evoluem ao longo do ano? Há parlamentares ou fornecedores com comportamento destoante do conjunto?

3. API escolhida e justificativa

Escolhi a **API de Dados Abertos da Câmara dos Deputados** por três motivos. Primeiro, é uma fonte oficial, pública e atualizada, com documentação clara (padrão OpenAPI/Swagger) e sem necessidade de chave de acesso. Segundo, oferece o recurso de despesas por parlamentar com paginação bem definida, o que exercita exatamente as competências pedidas no projeto (coleta automatizada, paginação e tratamento de erros). Terceiro, o tema dos gastos públicos é socialmente relevante e permite análises ricas por categoria, partido, estado e fornecedor.

4. Endpoints utilizados

Foram utilizados dois endpoints da versão 2 da API (/api/v2):

- GET /deputados — lista os parlamentares em exercício, com partido e UF;
- GET /deputados/{id}/despesas — retorna as despesas da CEAP de cada deputado, com paginação.

5. Explicação do script de coleta

O script coleta.py percorre primeiro a lista de deputados e depois, para cada um, todas as páginas de despesas. A função central é um GET resiliente, que trata os erros mais comuns da API:

```
def _get(url, params):
    for tentativa in range(1, MAX_TENTATIVAS+1):
        resp = requests.get(url, params, timeout=35)
        if resp.status_code == 200: return resp.json()
        if status in (429, 500, 502, 503, 504): espera_e_repete()
```

Destaco três cuidados: (1) **paginação**, controlada pelos links rel='next' que a própria API devolve; (2) **tratamento de erros**, com até seis tentativas e espera exponencial (backoff) — necessário porque a API retorna HTTP 504 esporádico sob carga; e (3) **checkpoint**: cada deputado já coletado é gravado em disco (formato JSON Lines), permitindo retomar a coleta sem perder o que já foi baixado.

6. Tratamentos realizados nos dados

Após a coleta, o script `tratamento.py` executa a limpeza inicial:

- padronização de **datas** para o formato ISO (AAAA-MM-DD);
- conversão de **valores financeiros** para tipo numérico, tratando o separador decimal brasileiro;
- manutenção de **identificadores** (CNPJ/CPF, códigos) como texto — eles identificam, não quantificam;
- verificação de **campos nulos** e remoção de registros sem valor líquido (inúteis para a análise financeira);
- remoção de **duplicatas** pela combinação deputado + código + número do documento.

7. Modelo de dados

Os dados foram normalizados em três tabelas, em um modelo do tipo estrela simplificado: a tabela-fato **despesas** e as dimensões **deputados** e **fornecedores**. Um deputado possui muitas despesas (1:N) e um fornecedor aparece em muitas despesas (1:N).

Diagrama Entidade-Relacionamento — Pipeline de Gastos Públicos



PK = chave primária · FK = chave estrangeira · deputados (1) —< despesas >— (1) fornecedores

Figura 1 — Diagrama Entidade-Relacionamento.

Chaves primárias: deputados.id_deputado; fornecedores.cnpj_cpf; despesas.id_despesa. **Chaves estrangeiras:** despesas.id_deputado → deputados; despesas.cnpj_cpf_fornecedor → fornecedores. Optei por uma chave primária interna em despesas porque o código de documento pode se repetir entre parlamentares.

8. Dicionário inicial de dados

Resumo da tabela-fato (o dicionário completo das três tabelas está em docs/dicionario_dados.md):

Campo	Tipo	Descrição	Exemplo
id_deputado	Inteiro (FK)	Identificador do parlamentar	204554
tipo_despesa	Texto	Categoria da despesa (CEAP)	PASSAGEM AÉREA
cnpj_cpf_fornecedor	Texto (FK)	Fornecedor da despesa	04.252.011/0001-10
data_documento	Data	Data do documento fiscal	2024-05-10
valor_liquido	Numérico	Valor ressarcido (análise)	1350.75
mes	Inteiro	Mês de referência	5

9. Evidências da execução

Indicador	Valor
Deputados coletados	477
Despesas armazenadas	181.714

Fornecedores distintos	20.234
Categorias de despesa	18
Período	2023-11-09 a 2025-03-27
Valor total (CEAP)	R\$ 207.543.146,12
Tempo de coleta	548.2 s

A execução também gera os arquivos `resumo_coleta.json` (quantitativos da coleta) e a base tratada em CSV/Parquet, além do banco `gastos_publicos.db`.

10. Considerações parciais

A base está coletada, tratada e armazenada de forma estruturada, atendendo ao objetivo da Entrega 1. A principal dificuldade foi a instabilidade pontual da API (HTTP 504), contornada com a política de retentativa e o checkpoint. Como limitação, registro que a CEAP representa apenas parte dos gastos públicos (a cota parlamentar), e que valores líquidos negativos (estornos) existem em pequena quantidade e serão tratados como casos específicos na análise. A base já está pronta para a etapa de análise exploratória, dashboard e Machine Learning.